

UNIVERSIDADE DE SÃO PAULO
FACULDADE DE ECONOMIA, ADMINISTRAÇÃO E CONTABILIDADE DE
RIBEIRÃO PRETO – FEA-RP
DEPARTAMENTO DE ADMINISTRAÇÃO
RCC4705 - Estatística Básica

RCC4705 - Estatística Básica

**Relatorio: “Café, Sono e Saúde: Evidências do dataset Global Coffee Health
(Kaggle.com)”**

Alessandro Saladino nºUSP 16995880

Sumário

Introdução e Objetivo	3
Perguntas de pesquisa:	3
Importação e preparação	4
Estatística descritiva	6
Hipótese 1: Quem bebe mais de 4 xícaras por dia dorme menos?	8
Hipótese 2: O consumo elevado está associado a níveis de estresse mais altos?	10
Hipótese 3: O café prediz as horas de sono (controlando variáveis)?	11
Verificação de pressupostos	13
Conclusão	14
Apêndice: Códigos Stata	15
Bibliografia	16

Introdução e Objetivo

O tema escolhido para o relatório foi “Café, Sono e Saúde: Evidências do dataset Global Coffee Health (Kaggle.com)”.

O café é uma das bebidas mais consumidas no mundo, presente em diversos países e culturas (Amrouk, E.M.; Palmeri, F.; Magrini, E.;2025). Sabemos que ele traz benefícios, como aumento de atenção e energia, mas também pode impactar o sono e o estresse. Minha ideia foi justamente investigar essas relações de forma quantitativa, utilizando uma base de dados bastante rica.

O objetivo geral do meu trabalho é investigar a relação entre consumo de café, sono e estresse utilizando o Global Coffee Health Dataset, que contém 10.000 observações de 20 países. (10.000 observações, 16 variáveis: demografia, consumo de café e cafeína, sono, IMC, frequência cardíaca, estresse, atividade física, hábitos e ocupação).

O Objetivo específico é avaliar a associação entre consumo de café e sono (horas e qualidade), e verificar se o consumo elevado está relacionado a maior estresse.

Utilizei o software STATA, aplicando técnicas de estatística descritiva, testes de hipóteses e regressão.

Perguntas de pesquisa:

O foco será responder a três perguntas de pesquisa:

1. Quem bebe mais de 4 xícaras por dia dorme menos?
2. O consumo elevado está associado a níveis de estresse mais altos?
3. O café prediz as horas de sono? (Controlando por idade, IMC e hábitos)

Importação e preparação

Primeiro, eu defini o separador decimal como vírgula, porque no Brasil os números usam vírgula em vez de ponto. Isso evita problemas de leitura dos dados.

Em seguida, importei a base a partir do Excel usando “import Excel” especificando o caminho do arquivo e indicando que a primeira linha contém os nomes das variáveis.

Depois, confirmei com o comando “describe”, que tínhamos exatamente 10 mil observações e 16 variáveis, conforme esperado.

Confirmamos que temos 10.000 casos e 16 variáveis, incluindo consumo de café, sono, estresse, IMC, idade, hábitos e outros fatores.”

O código utilizado nessa primeira parte deu esse resultado:

Notei que algumas variáveis estavam registradas em escala multiplicada por 10, como as horas de sono apareciam como 66 em vez de 6,6, e o IMC como 239 em vez de 23,9. Para corrigir, criei variáveis dividindo por 10, de forma que os valores passassem a representar corretamente horas de sono, IMC e atividade física. Esse ajuste é importante para garantir a interpretação adequada dos resultados.

Resultados no Stata:

1. set dp comma
2. import excel "C:\Users\Alessandro\Desktop\Prova Estatística\Global Coffee Health Dataset.xlsx", firstrow clear
(16 vars, 10,000 obs)
3. describe
Contains data

Observations: 10.000

Variables: 16

Variable	Storage	Display	Value
name	type	format	label

Variable label

ID	int	%10.0g	ID
Age	byte	%10.0g	Age
Gender	str6	%9s	Gender
Country	str11	%11s	Country
Coffee_Intake	byte	%10.0g	Coffee_Intake
Caffeine_mg	int	%10.0g	Caffeine_mg
Sleep_Hours	byte	%10.0g	Sleep_Hours
Sleep_Quality	str9	%9s	Sleep_Quality
BMI	int	%10.0g	BMI
Heart_Rate	int	%10.0g	Heart_Rate
Stress_Level	str6	%9s	Stress_Level
Physical_Activity_Hours	int	%10.0g	Physical_Activity_Hours
Health_Issues	str8	%9s	Health_Issues
Occupation	str10	%10s	Occupation
Smoking	byte	%10.0g	Smoking
Alcohol_Consumption	byte	%10.0g	Alcohol_Consumption

4. gen Sleep_Hours_real = Sleep_Hours/10
5. gen BMI_real = BMI/10
6. gen Physical_Activity_real = Physical_Activity_Hours/10
7. replace Sleep_Hours = Sleep_Hours/10

variable Sleep_Hours was byte now float

(10.000 real changes made)

8. replace BMI = BMI/10

variable BMI was int now float

(10.000 real changes made)

9. `replace Physical_Activity_Hours = Physical_Activity_Hours/10`

variable `Physical_Activity_Hours` was int now float

(9.973 real changes made)

Estatística descritiva

Antes de responder às hipóteses, fiz uma estatística descritiva para entender melhor o perfil da amostra.

Com o comando “summarize”, obtive que, em média, os participantes consumiam 6,6 horas de sono por noite (com desvio padrão de 1,2 hora), tinham IMC médio de 24 e praticavam cerca de 7,5

horas de atividade física por semana. Esses valores são plausíveis e refletem um perfil de adultos de diferentes países.

Ao analisar variáveis categóricas com “tabulate”, vi que a maioria declarou ter boa qualidade de sono (56%), enquanto 13,5% relataram sono excelente e 9,6% relataram sono ruim.

Quanto ao estresse, quase 70% relataram níveis baixos, 20,5% médios e cerca de 9,6% altos.

Essas informações iniciais são importantes porque nos mostram que, embora a maioria durma bem e tenha baixo estresse, existe uma parcela considerável que sofre com sono ruim ou estresse elevado, justamente os grupos que podem estar associados ao alto consumo de café.

Resultados no Stata:

1. summarize Sleep_Hours_real BMI_real Physical_Activity_real

Variable	Obs	Mean	Std. dev.	Min	Max
-----+-----					
Sleep_Hour~1	10.000	6,63622	1,222055	3	10
BMI_real	10.000	23,98686	3,906411	15	38,2
Physical_A~1	10.000	7,48704	4,31518	0	15

2. tabulate Sleep_Quality

Sleep_Quali	Freq.	Percent	Cum.
-----+-----			
Excellent	1352	13,52	13,52
Fair	2050	20,50	34,02
Good	5637	56,37	90,39
Poor	961	9,61	100,00
-----+-----			
Total	10000	100,00	

3. tabulate Stress_Level

Stress_Level			
1	Freq.	Percent	Cum.
-----+-----			
High	961	9,61	9,61
Low	6989	69,89	79,50
Medium	2050	20,50	100,00
-----+-----			
Total	10000	100,00	

Hipótese 1: Quem bebe mais de 4 xícaras por dia dorme menos?

Para a primeira hipótese, criei uma variável dummy chamada high_coffee, que assume valor 1 quando o consumo é superior a 4 xícaras por dia e 0 caso contrário.

Depois, apliquei um teste t de médias para comparar as horas de sono entre os dois grupos.

Os resultados mostraram que:

1. Quem bebe até 4 xícaras dorme em média 6,98 horas por noite.
2. Quem bebe mais de 4 xícaras dorme em média 6,60 horas.

A diferença é de aproximadamente 0,38 hora por noite, ou seja, quase 23 minutos a menos de sono.

Essa diferença é estatisticamente significativa, com p-valor menor que 0,001.

Portanto, a hipótese é confirmada: quem bebe muito café dorme significativamente menos.

Resultados no Stata:

1. gen high_coffee = (Coffee_Intake > 4)
2. ttest Sleep_Hours, by(high_coffee)

Two-sample t test with equal variances

```
-----+-----
      Group |   Obs    Mean   Std. err.   Std. dev.   [95% conf. interval]
-----+-----
      0 |   893  6,985106   ,0410413   1,226443   6,904558   7,065655
      1 |  9.107  6,602009   ,0127456   1,216316   6,577025   6,626994
-----+-----
Combined | 10.000  6,63622   ,0122206   1,222055   6,612265   6,660175
-----+-----
      diff |      ,383097   ,0426832           ,2994294   ,4667645
-----+-----

diff = mean(0) - mean(1)                                t =  8,9754

H0: diff = 0                                             Degrees of freedom =  9998

      Ha: diff < 0           Ha: diff != 0           Ha: diff > 0
Pr(T < t) = 1,0000      Pr(|T| > |t|) = 0,0000      Pr(T > t) = 0,0000
```

Hipótese 2: O consumo elevado está associado a níveis de estresse mais altos?

Para a segunda hipótese, usei um teste do qui-quadrado de independência, cruzando a variável `high_coffee` com os níveis de estresse.

Os resultados mostraram que:

1. Entre os grandes consumidores de café, a proporção de pessoas com estresse alto foi maior.
2. O qui-quadrado resultou em $\chi^2 = 37,85$, $p < 0,001$, indicando associação significativa.

Isso significa que não podemos considerar o consumo de café e os níveis de estresse como independentes. Existe uma relação estatisticamente comprovada: quem bebe mais café tende a apresentar níveis mais altos de estresse.

Resultados no Stata:

```
1. tabulate Stress_Level high_coffee, chi2
```

Stress_Lev		high_coffee	
el	0	1	Total
-----+-----+-----			
High	48	913	961
Low	701	6288	6989
Medium	144	1906	2050
-----+-----+-----			
Total	893	9107	10000

Pearson chi2(2) = 37,8523 Pr = 0,000

Hipótese 3: O café prediz as horas de sono (controlando variáveis)?

Na terceira hipótese, utilizei uma regressão linear múltipla.

A variável dependente foi Sleep_Hours (horas de sono corrigidas), e a principal variável explicativa foi Coffee_Intake.

Além disso, incluí controles importantes: idade, IMC, tabagismo, consumo de álcool e atividade física.

Os resultados mostraram que:

- O coeficiente de Coffee_Intake foi $-0,016$, com $p\text{-valor} < 0,001$.
Isso significa que, para cada xícara de café a mais consumida por dia, a pessoa dorme em média $0,016$ hora a menos, ou seja, cerca de 1 minuto a menos por noite. Pode parecer

pouco, mas acumulado em grandes quantidades de café ou ao longo de semanas, o impacto é considerável.

- Os demais controles (idade, IMC, fumo, álcool, atividade física) não foram significativos, mostrando que, neste modelo, o principal preditor do sono foi o café.
- O R^2 do modelo foi 0,036, ou seja, cerca de 3,6% da variabilidade das horas de sono é explicada por esse conjunto de variáveis. Esse valor é baixo, mas esperado em pesquisas com comportamento humano, onde múltiplos fatores influenciam o sono.

Resultados no Stata:

1. regress Sleep_Hours Coffee_Intake Age BMI Smoking Alcohol_Consumption
Physical_Activity_Hours

```

Source |      SS       df       MS    Number of obs   =    10.000
-----+-----
               F(6, 9993)    =    63,08

Model | 544,945564      6 90,8242607  Prob > F      =    0,0000

Residual | 14387,7556    9.993 1,43978341  R-squared    =    0,0365
-----+-----
               Adj R-squared =    0,0359

Total | 14932,7012    9.999 1,49341946  Root MSE    =    1,1999

-----+-----

Sleep_Hours | Coefficient Std. err.    t    P>|t|    [95% conf. interval]
-----+-----

Coffee_Intake | -,0160353   ,0008276  -19,38  0,000   -,0176576   -,0144131

Age | ,0003108   ,0010754    0,29  0,773   -,0017972   ,0024188

BMI | ,0020935   ,0030725    0,68  0,496   -,0039291   ,0081161

Smoking | ,0299773   ,0299862    1,00  0,317   -,0288018   ,0887563

Alcohol_Consumption | -,0130611   ,0261747   -0,50  0,618   -,0643689   ,0382466

Physical_Activity_Hours | -,0029369   ,0027815   -1,06  0,291   -,0083892   ,0025154

_cons | 6,997413   ,089084   78,55  0,000    6,82279    7,172035

```

Verificação de pressupostos

Para garantir a robustez da análise, apliquei testes de normalidade na variável dependente.

O sktest rejeitou normalidade com $p = 0,008$, enquanto o swilk não rejeitou ($p = 0,219$). Essa diferença ocorre porque, em grandes amostras, até pequenas variações produzem significância em alguns testes.

De todo modo, como o tamanho da amostra é muito grande (10 mil observações), os resultados da regressão permanecem confiáveis graças ao Teorema Central do Limite.

Resultados no Stata:

1. `sktest Sleep_Hours`

Skewness and kurtosis tests for normality

----- Joint test -----

Variable	Obs	Pr(skewness)	Pr(kurtosis)	Adj chi2(2)	Prob>chi2
-----+-----					
Sleep_Hours	10.000	0,4543	0,0027	9,52	0,0085

2. swilk Sleep_Hours

Shapiro–Wilk W test for normal data

Variable	Obs	W	V	z	Prob>z
-----+-----					
Sleep_Hours	10.000	0,99973	1,335	0,774	0,21937

Conclusão

Para concluir, recapitulo as principais conclusões:

1. Quem bebe mais de 4 xícaras de café dorme em média 23 minutos a menos por noite.
2. O consumo elevado de café está associado a níveis mais altos de estresse.
3. O café é um preditor negativo das horas de sono, mesmo quando controlamos por idade, IMC e hábitos de saúde.

Esses resultados estão em linha com o que a geralmente os médicos sugere: o café pode trazer benefícios no curto prazo, mas o consumo elevado prejudica a qualidade e a duração do sono, além de estar associado a maior estresse.

Portanto, o estudo mostra que é preciso equilíbrio: consumir café com moderação pode ser positivo, mas exagerar traz consequências negativas para a saúde e o bem-estar.

Apêndice: Códigos Stata

- set dp comma
- import excel "Global Coffee Health Dataset.xlsx", firstrow clear
- describe
- gen Sleep_Hours_real = Sleep_Hours/10
- gen BMI_real = BMI/10
- gen Physical_Activity_real = Physical_Activity_Hours/10
- replace Sleep_Hours = Sleep_Hours/10
- replace BMI = BMI/10
- replace Physical_Activity_Hours = Physical_Activity_Hours/10
- summarize Sleep_Hours_real BMI_real Physical_Activity_real
- tabulate Sleep_Quality
- tabulate Stress_Level
- gen high_coffee = (Coffee_Intake > 4)
- ttest Sleep_Hours, by(high_coffee)
- tabulate Stress_Level high_coffee, chi2

- regress Sleep_Hours Coffee_Intake Age BMI Smoking Alcohol_Consumption Physical_Activity_Hours
- sktest Sleep_Hours
- swilk Sleep_Hours

Bibliografia

- Food and Agriculture Organization of the United Nations. (2025). Global coffee market and recent price developments. Author: Amrouk, E.M.; Palmeri, F.; Magrini, E.; Publisher: FAO.